



Instituto Infnet

Bloco: 2º Ciclo - Fundamentos do Processamento de Dados

Python para Processamento de Dados [26E2_4]

Strings (str) - Continuação

Indexação (acessando caracteres individuais)

```
poema_carlos_drummond_fragmento_1 = '''
Que pode uma criatura senão,
entre criaturas, amar?
amar e esquecer,
amar e malamar,
amar, desamar, amar?
sempre, e até de olhos vidrados, amar?
'''

print(poema_carlos_drummond_fragmento_1)
```

```
Que pode uma criatura senão,
entre criaturas, amar?
amar e esquecer,
amar e malamar,
amar, desamar, amar?
sempre, e até de olhos vidrados, amar?
```

```
poema_carlos_drummond_fragmento_1[0]
```

```
'\n'
```

```
poema_carlos_drummond_fragmento_1[1]
```

```
'Q'
```

```
poema_carlos_drummond_fragmento_1[-1]
```

```
'\n'
```

```
poema_carlos_drummond_fragmento_1[-2]
```

```
'?'
```



Fatiamento (slicing) - obtendo partes da string

- [:] extracts the entire sequence from start to end.
- [start :] specifies from the start offset to the end.
- [: end] specifies from the beginning to the end offset minus 1.
- [start : end] indicates from the start offset to the end offset minus 1.
- [start : end : step] extracts from the start offset to the end offset minus 1, skipping characters by step.

```
poema_carlos_drummond_fragmento_1[1:4]
```

```
'Que'
```

```
poema_carlos_drummond_fragmento_1[5:]
```

```
'pode uma criatura senão,\nentre criaturas, amar?\namar e esquecer,\namar e malamar,\namar, desamar, amar?\nsempre, e até de olho
```

```
poema_carlos_drummond_fragmento_1[:10]
```

```
'\nQue pode '
```

```
poema_carlos_drummond_fragmento_1[11:30]
```

```
'ma criatura senão,\n'
```

```
poema_carlos_drummond_fragmento_1[11:30:2]
```

```
'm rauasno\n'
```

```
poema_carlos_drummond_fragmento_1[:-1]
```

```
'\n?rama ,sodardiv sohlo ed éta e ,erpmes\n?rama ,ramased ,rama\n,ramalam e rama\n,receuqse e rama\n?rama ,sarutairc ertne\n,oãne
```


```
poema_carlos_drummond_fragmento_1[:2]
```

```
'\nu oueacitr eã,etecitr mr\nmreeqee,aa aaa,aa,dsmr mr\nnepe t eohsvdao,aa?'
```

Por que strings são importantes?

Uma aplicação em Processamento de Linguagem Natural (PLN)

O Processamento de Linguagem Natural (PLN) é um campo de pesquisa que tem como objetivo investigar e propor métodos e sistemas de processamento computacional da linguagem humana. Na área da Ciência da Computação, PLN está ligado à área de Inteligência Artificial (IA) e também está intrinsecamente relacionada à Linguística Computacional [1].




Para desenvolver praticamente qualquer aplicação de PLN, é necessário realizar fases/etapas que convencionamos chamar de pré-processamento. Nesse pré-processamento, algumas tarefas usuais são: segmentação do texto em sentenças (sentencição), separação de palavras (tokenização), tokenização em subpalavras (vetorização de subtokens), normalização de palavras (lematização e radicalização), entre outras [1].

Etapas de Pré processamento em PLN



Exemplo prático



```
texto = '''Atualização da conjuntura econômica do cenário do Copom ambiente externo se mantém adverso Apesar da atenuação
print(texto)
```

```
Atualização da conjuntura econômica do cenário do Copom ambiente externo se mantém adverso Apesar da atenuação do estresse envolv
```

```
len(texto)
```

```
18517
```

```
type(texto)
```

```
str
```

```
# Etapa de Normalizacao
texto_normalizado = texto.lower()
print(texto_normalizado)
```

```
atualização da conjuntura econômica do cenário do copom ambiente externo se mantém adverso apesar da atenuação do estresse envolv
```

```
# Etapa de Tokenizacao (anagramas)
texto_normalizado_tokenizado = texto_normalizado.split()
print(texto_normalizado_tokenizado)
```

```
['atualização', 'da', 'conjuntura', 'econômica', 'do', 'cenário', 'do', 'copom', 'ambiente', 'externo', 'se', 'mantém', 'adverso']
```

```
# Etapa de remocao de stopwords
# passo 1: definir uma lista de stopwords
lista_de_stopwords = ['a', 'e', 'é', 'de', 'da', 'do', 'se', 'para', 'o', 'em', 'ou']
# passo 2: lista para guardar o texto sem stopwords
texto_normalizado_tokenizado_sem_stopwords = [] #criando uma lista vazia

# passo 3: popular a lista sem stopwords

for token in texto_normalizado_tokenizado:
    if token not in lista_de_stopwords:
        texto_normalizado_tokenizado_sem_stopwords.append(token) # adicionando o token na lista de tokens sem stopwords

print(texto_normalizado_tokenizado_sem_stopwords)
```

```
['atualização', 'conjuntura', 'econômica', 'cenário', 'copom', 'ambiente', 'externo', 'mantém', 'adverso', 'apesar', 'atenuação',
```

```
# alguns resultados de analise
```

```
# modo hard:
numero_ocorrencia_copom = 0
numero_ocorrencia_juros = 0
numero_ocorrencia_inflacao = 0
numero_ocorrencia_cenario = 0
```

```
for token in texto_normalizado_tokenizado_sem_stopwords:
    if token == 'copom':
        numero_ocorrencia_copom += 1

    if token == 'juros':
        numero_ocorrencia_juros += 1

    if token == 'inflação':
        numero_ocorrencia_inflacao += 1

    if token == 'cenário':
        numero_ocorrencia_cenario += 1
```

```
print(f'Numero de ocorrencia da palavra COPOM: {numero_ocorrencia_copom}')
print(f'Numero de ocorrencia da palavra JUROS: {numero_ocorrencia_juros}')
print(f'Numero de ocorrencia da palavra INFLAÇÃO: {numero_ocorrencia_inflacao}')
print(f'Numero de ocorrencia da palavra CENÁRIO: {numero_ocorrencia_cenario}')
```

```
Numero de ocorrencia da palavra COPOM: 12
Numero de ocorrencia da palavra JUROS: 8
Numero de ocorrencia da palavra INFLAÇÃO: 45
Numero de ocorrencia da palavra CENÁRIO: 9
```

```
print(texto_normalizado_tokenizado_sem_stopwords)
```

```
['atualização', 'conjuntura', 'econômica', 'cenário', 'copom', 'ambiente', 'externo', 'mantém', 'adverso', 'apesar', 'atenuação',
```

```
texto_pre_processado = ' '.join(texto_normalizado_tokenizado_sem_stopwords)
print(texto_pre_processado)
print(len(texto_pre_processado))
```

```
atualização conjuntura econômica cenário copom ambiente externo mantém adverso apesar atenuação estresse envolvendo bancos nos eu
16888
```

```
type(texto_pre_processado)
```

```
str
```

Referência Bibliográfica

[1] Caseli, H.M.; Nunes, M.G.V. (org.) Processamento de Linguagem Natural: Conceitos, Técnicas e Aplicações em Português. 4 ed. BPLN, 2026. ISBN 978-65-02-00178-3. Disponível em: <https://brasileiraspln.ufscar.br/livro-pln-4ed>.

Conteúdo para aprofundamento

[Documentação oficial sobre strings](#)